TRƯỜNG ĐẠI HỌC SÀI GÒN

KHOA CÔNG NGHỆ THÔNG TIN



Học sâu

Đề tài: Tóm tắt 2 bài báo về DL và Nobel Vật lý 2024

Họ và tên sinh viên: Nguyễn Hoàng Tín

Mã số sinh viên: 3123411299

Lớp: DCT123C3 Khoa: Công nghệ Thông tin

Thành phố Hồ Chí Minh – Tháng 09/2026

TÓM TẮT BÀI BÁO: "DEEP LEARNING"

Yann LeCun, Yoshua Bengio & Geoffrey Hinton — Nature, Vol. 521, pp. 436–444, 2015

1. Vấn đề

Các hệ thống Deep Learning truyền thống không thể xử lý trực tiếp dữ liệu tự nhiên ở dạng thô (pixel ảnh, sóng âm, ký tự). Suốt nhiều thập kỷ, việc xây dựng hệ thống đòi hỏi các chuyên gia phải thiết kế thủ công các đặc trưng (như SIFT, HOG cho ảnh; MFCC cho giọng nói). Quy trình này tốn nhiều công sức, mang tính đặc thù cao và dễ bị phá vỡ khi phân phối dữ liệu thực tế bị thay đổi. Một bộ phân loại tốt cần phải đồng thời thực hiện hai nhiệm vụ đối nghịch: cực kỳ nhạy cảm với những chi tiết nhỏ để phân biệt các danh mục khác nhau, nhưng lại phải hoàn toàn bất biến trước các biến thiên không liên quan (như thay đổi góc nhìn, tư thế, điều kiện ánh sáng, phông nền). Các mô hình phân loại nông (shallow classifiers) hoạt động trên mức pixel thô hoàn toàn bất lực trước bài toán này.

2. Bài toán cần giải quyết

Làm thế nào để máy tính đưa trực tiếp dữ liệu thô vào và tự động học ra các tầng đặc trưng không cần con người can thiệp? Đồng thời, làm sao tối ưu hóa thành công các mạng nơ-ron nhiều tầng khi quan niệm phổ biến thời đó cho rằng gradient descent sẽ luôn bị bế tắc tại các cực tiểu cục bộ kém?

3. Hướng đi giải quyết

• Lan truyền ngược (Backpropagation) và Tối ưu hóa Gradient ngẫu nhiên (SGD): Tận dụng thuật toán Backpropagation dựa trên quy tắc chuỗi (chain rule) để tính gradient hàm mục tiêu ngược từ tầng ra về tầng vào. Kết hợp Stochastic Gradient Descent (SGD) cập nhật trọng số theo từng nhóm nhỏ, giúp tìm ra các bộ trọng số tối ưu nhanh hơn so với các thuật toán tối ưu hóa phức tạp.

• Bộ ba đột phá thực nghiệm (ReLU, Dropout, GPU): Sử dụng hàm kích hoạt ReLU f(z) = max(0,z) không bị bão hòa, giải quyết triệt tiêu gradient và cho phép huấn luyện mạng sâu không cần tiền huấn luyện không giám sát; áp dụng kỹ thuật điều chuẩn Dropout (tắt ngẫu nhiên nơ-ron) chống quá khớp hiệu quả; tận dụng GPU tăng tốc tính toán 10–20 lần, rút ngắn thời gian huấn luyện từ nhiều tuần xuống vài giờ.

• Mạng tích chập (CNN) cho dữ liệu không gian: Xây dựng kiến trúc lấy cảm hứng từ tế bào thị giác với 4 nguyên lý cốt lõi: kết nối cục bộ, chia sẻ trọng số, phép gộp và xếp chồng nhiều lớp để tự động khám phá phân cấp đặc trưng có tính cấu thành.

• Mạng hồi quy (RNN) & LSTM cho dữ liệu tuần tự: RNN duy trì vector trạng thái ẩn st ghi nhớ thông tin lịch sử của chuỗi. Kiến trúc LSTM bổ sung các ô nhớ cùng cổng quên, cổng nhập, cổng xuất giúp ghi nhớ thông tin dài hạn, khắc phục hoàn toàn vấn đề bùng nổ hoặc triệt tiêu gradient qua thời gian.

• Biểu diễn phân tán và mô hình hóa chuỗi (Word Vectors & Seq2Seq): Ánh xạ từ ngữ thành vector liên tục đem lại lợi thế hàm mũ về khả năng biểu diễn. Kết hợp mô hình Encoder-Decoder cho phép dịch máy tự động và sinh chú thích hình ảnh.

• Khám phá bản chất bề mặt tối ưu: Chỉ ra rằng với mạng nơ-ron lớn, cực tiểu cục bộ không phải trở ngại chính; bề mặt lỗi thực chất chứa vô số điểm yên ngựa và phần lớn chúng đều có mức sai số xấp xỉ nhau, không ảnh hưởng đến chất lượng nghiệm.

4. Kết quả sau khi giải quyết

• Đột phá thị giác máy tính: AlexNet cắt giảm gần một nửa tỷ lệ lỗi trên tập dữ liệu ImageNet 2012 (từ 26.2% xuống 15.3%), sau đó GoogLeNet đạt ~6.7%, đưa CNN trở thành phương pháp thống trị tuyệt đối trong nhận dạng và phát hiện vật thể.

• **Cách mạng nhận dạng giọng nói:** Mạng nơ-ron sâu thay thế hoàn toàn mô hình GMM-HMM truyền thống, trở thành ứng dụng công nghiệp lớn đầu tiên và được tích hợp trực tiếp trên điện thoại Android từ năm 2012.

• **Chuyển biến trong xử lý ngôn ngữ tự nhiên:** Kiến trúc Seq2Seq và Memory Networks đạt kết quả cạnh tranh trực tiếp với các hệ thống dịch máy và trả lời câu hỏi suy luận phức tạp dựa trên luật truyền thống.

• **Ứng dụng khoa học rộng rãi:** Vượt trội các mô hình cũ trong dự đoán hoạt tính phân tử thuốc, phân tích dữ liệu máy gia tốc hạt, tái tạo bản đồ mạch não và phân tích biến dị gen DNA.

• **Tầm nhìn tương lai được chứng thực (2026):** Các dự đoán trong bài đều đã trở thành trụ cột AI ngày nay: học tự giám sát (GPT, BERT), cơ chế chú ý chọn lọc (Transformer), và học tăng cường kết hợp học sâu (AlphaGo, RLHF).

TÓM TẮT: GIẢI NOBEL VẬT LÝ 2024

John J. Hopfield & Geoffrey E. Hinton — "Foundational discoveries and inventions that enable machine learning with artificial neural networks"

1. Vấn đề

Từ thập niên 1950–1970, máy tính chỉ thực hiện các quy trình tính toán tuần tự theo chỉ dẫn định sẵn, hoàn toàn bất lực trước bài toán nhận dạng mẫu mà não bộ sinh học làm rất tốt. Mô hình Perceptron của Rosenblatt (1957) mở đầu cho mạng nơ-ron nhưng cuốn sách năm 1969 của Minsky & Papert đã chỉ ra hạn chế chí mạng: Perceptron không giải được các bài toán phi tuyến đơn giản như XOR. Phát hiện này làm suy giảm niềm tin vào mạng nơ-ron, dẫn tới việc cắt giảm tài trợ và đẩy ngành nghiên cứu vào "Mùa đông AI" suốt hơn một thập kỷ. Đồng thời, máy tính cổ điển chỉ lưu trữ theo địa chỉ nhớ cố định, trong khi não bộ có bộ nhớ kết hợp, có thể tái hiện toàn bộ ký ức chỉ từ một mẩu manh mối rời rạc; thời điểm đó hoàn toàn thiếu vắng một mô hình vật lý/toán học giải thích được cơ chế này.

2. Bài toán cần giải quyết

• Lưu trữ và khôi phục mẫu (Bộ nhớ kết hợp): Làm thế nào để xây dựng một mạng nơ-ron lưu trữ phân tán nhiều mẫu dữ liệu cùng lúc, và có khả năng tự sửa lỗi để khôi phục lại mẫu nguyên bản khi dữ liệu đầu vào bị méo mó, nhiễu hoặc khuyết thiếu?

• Học không giám sát và mô hình sinh xác suất: Làm sao để máy tính tự động nắm bắt các quy luật và đặc trưng tiềm ẩn trong dữ liệu mà không cần con người gán nhãn, từ đó có thể sinh ra các mẫu dữ liệu mới hợp lệ?

• Khởi tạo và huấn luyện mạng nơ-ron sâu: Làm sao vượt qua rào cản tối ưu hóa để huấn luyện thành công các mạng nơ-ron nhiều tầng ẩn dày đặc mà không bị kẹt ở các điểm tối ưu cục bộ?

3. Hướng đi giải quyết

• Mạng Hopfield và Bề mặt năng lượng (Hopfield, 1982): Ứng dụng mô hình spin từ tính trong vật lý chất rắn. Mạng gồm N nút nhị phân liên kết đối xứng với hàm năng lượng $E = -\Sigma\, w_i\ \ s_i s\ \ $. Quá trình học bằng quy tắc Hebb đóng vai trò kiến tạo các thung lũng năng lượng tương ứng với các mẫu cần nhớ. Khi nhận đầu vào chứa dữ liệu nhiễu, mạng cập nhật trạng thái như một viên bi tự lăn xuống đáy thung lũng gần nhất để khôi phục mẫu gốc. Dung lượng lưu trữ được làm sáng tỏ bằng lý thuyết vật lý spin glass.

• Mạng Analog và Tối ưu hóa tổ hợp (Hopfield & Tank, 1985): Mở rộng mạng sang dạng tín hiệu liên tục mô phỏng phương trình chuyển động của mạch điện tử. Bằng cách giảm dần nhiệt độ hiệu dụng tương tự phương pháp tôi luyện mô phỏng, mạng có thể giải các bài toán tối ưu hóa tổ hợp phi tuyến phức tạp.

• Cỗ máy Boltzmann — Mô hình sinh xác suất (Hinton & Sejnowski, 1985): Tích hợp xác suất và nhiệt độ ảo T từ phân phối Boltzmann của nhiệt động lực học thế kỷ 19: $P(s) \propto \exp(-E/T)$. Kiến trúc chia thành nút hiển thị (visible) và nút ẩn (hidden) giúp cỗ máy Boltzmann trở thành mô hình sinh đầu tiên, tự học phân phối xác suất và có khả năng nhảy qua các rào cản năng lượng để tìm trạng thái tối ưu toàn cục.

• Khôi phục Lan truyền ngược (Rumelhart, Hinton & Williams, 1986): Chứng minh thuật toán Backpropagation tính đạo hàm theo quy tắc chuỗi cho phép huấn luyện mạng có lớp ẩn, chính thức giải quyết bài toán XOR mà Perceptron từng bất lực, đồng thời giải mã vai trò tự tìm biểu diễn đặc trưng của các nút ẩn.

• **Mạng RBM và Tiền huấn luyện từng tầng (Hinton, 2002 & 2006):** Phát minh Restricted Boltzmann Machine đi kèm thuật toán Contrastive Divergence giúp tăng tốc độ học vượt bậc. Bằng cách xếp chồng nhiều RBM để tiền huấn luyện không giám sát từng tầng từ dưới lên, mạng có được điểm khởi tạo trọng số lý tưởng trước khi tinh chỉnh bằng Backpropagation, chính thức phá vỡ bế tắc huấn luyện mạng sâu và mở ra kỷ nguyên Deep Learning.

• **Đặt nền tảng cho các kiến trúc kế thừa:** Tài liệu Nobel khẳng định các công trình này đã tạo tiền đề phát triển mạng tích chập CNN (LeCun & Bengio, lấy cảm hứng từ thị giác của Hubel & Wiesel - Nobel Y học 1981) và mạng hồi quy LSTM (Hochreiter & Schmidhuber, 1997).

4. Kết quả sau khi giải quyết

• **Khẳng định tính toán nơ-ron bằng vật lý:** Chứng minh các hiện tượng tập thể trong các hệ thống vật lý có thể chuyển hóa thành năng lực tính toán thông minh — bộ nhớ phân tán, khả năng tự sửa lỗi và tối ưu hóa tổ hợp.

• **Khởi xướng cuộc cách mạng Deep Learning:** Kỹ thuật tiền huấn luyện RBM của Hinton năm 2006 trực tiếp hồi sinh ngành mạng nơ-ron, dẫn đến sự bùng nổ của AlexNet (2012), mạng tích chập sâu, Transformers và các mô hình ngôn ngữ lớn (LLM) hiện nay.

• **Đóng góp ngược trở lại nền Vật lý và Khoa học tự nhiên:** Mạng nơ-ron nhân tạo trở thành công cụ đắc lực hỗ trợ phát hiện hạt Higgs boson tại CERN (2012), xử lý dữ liệu chụp ảnh Lỗ đen (EHT), tái hiện bản đồ neutrino dải Ngân Hà (IceCube), phát hiện ngoại hành tinh (sứ mệnh Kepler), và nâng cao độ phân giải mô hình khí hậu.

• **Đột phá y sinh ngoạn mục:** Mô hình AlphaFold đã giải mã cấu trúc 3D của gần như toàn bộ protein đã biết, giải quyết bài toán thách thức hơn 50 năm của sinh học phân tử.

• **Tôn vinh lịch sử:** Giải Nobel Vật lý 2024 trao cho John Hopfield và Geoffrey Hinton, ghi nhận mối liên kết chặt chẽ và sâu sắc giữa các quy luật vật lý nền tảng và sự ra đời của Trí tuệ nhân tạo hiện đại.